

인공지능 모델 탄소 배출량 측정 및 시각화 도구 분석: 체계적 문헌고찰

Analysis of the Tools for Measuring and Visualizing AI Model Carbon Emissions: A Systematic Review

김유빈*

Yubin Kim

이화여자대학교

Ewha Womans University
cosmos2718@ewha.ac.kr

문윤서*

Yunseo Moon

서울시립대학교

University of Seoul
copel0317@gmail.com

손재범

Jaebeom Son

서강대학교

Sogang University
thswojia98@gmail.com

박민지

Minji Park

성균관대학교

Sungkyunkwan University
mj.park@g.skku.edu

민지유

Jiyoo Min

서울시립대학교

University of Seoul
jiyum0618@gmail.com

정형구⁺

Hyunggu Jung

서울대학교

Seoul National University
hyunggu@snu.ac.kr

요약문

본 연구는 인공지능 모델 개발 주기에서 발생하는 탄소 배출량을 측정하고 시각화하는 기술 개발 동향을 파악하기 위해 체계적 문헌고찰을 수행했다. 문헌 검색은 온라인 학술 데이터 베이스인 Scopus, IEEE Xplore, ACM Digital Library를 활용하여 2024년 11월까지 출판된 문헌에 대해 진행했고, PRISMA 가이드라인에 따라 포함 조건을 충족하는 5편의 논문을 분석 대상에 포함했다. 인공지능 모델 개발 주기에서 발생하는 탄소 배출량을 측정하고 시각화한 5편의 논문에 대해, 각 논문에서 평가한 인공지능 모델의 특성, 측정한 탄소 배출량 시각화 방법, 타깃 사용자를 체계적으로 분석했다. 현재까지의 탄소 배출량 측정 및 시각화 도구들은 시각화 과정에서 사용자와의 상호작용이 부족할 뿐만 아니라 사용자 평가를 진행하지 않았고, 타깃 사용자의 니즈 반영과 전처리 및 실험 과정에서의 탄소 배출량 측정이 부족하다는 점이 발견되었다. 본 연구는 이러한 발견을 토대로 현재까지의 기술개발 동향에 대한 체계적 이해와 더불어 지속 가능한 인공지능 도구 디자인을 위한 방향성을 제시했다.

주제어

지속 가능한 인공지능, 탄소 배출량, 시각화 도구, 체계적 문헌고찰

1 서론

복잡한 데이터셋과 대규모 아키텍처를 활용하는 현대의 인공지능 모델은 막대한 컴퓨팅 자원을 필요로 하며, 이는 탄소 배출량의 급격한 증가를 초래한다. GPT-3와 같은 대형 언어 모델 (LLM)을 훈련할 때 발생하는 탄소 배출량은 비행기가 샌프란시스코와 뉴욕을 3번 왕복할 때 발생하는 탄소 배출량(약 1.2톤)과 유사하며[1], 탄소 배출량의 증가는 기후 변화와 소외된 국가들의 환경적, 경제적 비용을 초래한다. Hope는 탄소 배출로 인한 사회적 비용이 연평균 약 3.2%씩 증가할 것으로 예측했다[2]. 온라인 커뮤니티에 공유되는 인공지능 모델의 수가 증가함에 따라, 개발과 사용 과정에서의 컴퓨팅 자원과 탄소 배출량도 증가할 것으로 예상된다[3]. 따라서 인공지능 개발자가 모델을 개발하거나 사용할 때 탄소 배출량을 확인하고 관리할 필요성이 커지고 있다[4].

최근 인공지능 모델 개발 및 사용 과정에서 발생하는 탄소 배출량을 측정하고 줄이기 위한 다양한 도구가 개발되고 있다[5,6]. 이에 더해, 이러한 도구들의 특성을 분석하는 문헌고찰 연구도 활발히 이루어지고 있다[7-9]. 예를 들어 선행 연구에서는 스마트시티[7], 의료[8]와 같은 다양한 분야에서 인공지능 모델이 환경에 미치는 영향을 정량적으로 평가한 사례들을 분석했다. 또한, 인공지능 모델의 훈련 과정에서 발생하는 탄소 배출량을 측정하기 위해 제안된 도구들의 특성을 분석하고 인공지능 실무자가 도구 선택 시 참고할 가이드라인을 제안했다[9]. 그러나 각 도구가 탄소 배출량을 사용자에게 어떻게 시각화하여 제공하는지 기존 문헌고찰 연구에서는 구

* 공동 1저자, ⁺ 교신저자

체적으로 다루지 않았으며, 어떻게 하면 사용자에게 탄소 배출량 정보를 시각적으로 이해하기 쉽게 제공하는 방법에 대한 분석이 부족했다는 한계도 존재한다.

따라서 본 연구는 2024 년 11 월 현재까지 출판된 문헌 중 인공지능 모델의 탄소 배출량을 측정하고 시각화한 도구만을 대상으로 체계적 문헌고찰 (Systematic Review) 을 수행하고자 한다. 이를 통해 현재까지 개발된 도구들의 특징과 한계점을 분석하고, 연구 동향을 체계적으로 파악하며, 앞으로의 도구 개발을 위한 지침을 제시하는 것을 목적으로 한다. 이로써 인공지능 개발자들에게 인공지능 모델의 탄소 배출량 측정 및 시각화 도구에 대한 종합적 이해와 연구 방향성을 제시하며, 해당 분야에 대한 추가 연구의 필요성을 환기시키고자 한다. 결과적으로, 사용자가 모델의 탄소 배출량을 확인하고 관리할 수 있는 도구를 개발하고, 지속 가능한 인공지능 개발을 위한 환경 조성에 기여할 수 있을 것으로 기대한다. 본 연구는 다음과 같은 연구 질문을 설정했다.

연구 질문 1. 개발한 도구로 어떤 인공지능 모델을 평가했는가?

연구 질문 2. 인공지능 모델 개발 주기의 어떤 단계에서 발생한 탄소 배출량을 측정했는가?

연구 질문 3. 측정한 탄소 배출량 시각화에 사용한 지표는 무엇인가?

연구 질문 4. 개발한 시각화 도구가 정보 시각화 레퍼런스 모델의 어떤 단계까지 지원하는가?

연구 질문 5. 개발한 시각화 도구의 타겟 사용자는 누구인가?

2 연구 방법

체계적 문헌고찰은 연구 질문에 답하기 위해 사전에 정해진 선정 기준에 맞는 모든 근거를 수집하여 분석하는 연구 방법이다[10]. 체계적 문헌고찰은 기존의 연구 요약 및 분석, 새로운 연구가 필요한 영역 식별과 방향성 제시를 목적으로 하며, 엄격하고 객관적으로 연구 주제를 검증할 수 있다는 장점이 있다. 본 연구는 Preferred Reporting Items for Systematic reviews and Meta-analysis (PRISMA)[11] 연구 지침에 따라 시행되었다.

2.1 문헌 검색

문헌 수집을 위해 Scopus, IEEE Xplore, ACM Digital Library 3 개의 온라인 데이터베이스에서 2024 년 11 월 까지 발표된 문헌에 대한 검색을 실시했다. 검색어는 ("carbon emissions" OR "carbon emission" OR "carbon intensity" OR "carbon footprints" OR "carbon




그림 1. 분석 대상 문헌 선별 과정

footprint") AND (AI OR "artificial intelligence" OR "machine learning" OR "deep learning") AND (measure OR track OR visualize) 을 포함했으며 제목, 초록 또는 키워드 중 하나 이상에 적용되었다. 그 결과 Scopus 에서 418 편, IEEE Xplore 에서 58 편, ACM Digital Library 에서 26 편이 검색되어, 총 502 편의 문헌이 수집되었다.

2.2 선정 기준

문헌의 포함 기준은 1) 인공지능 모델 개발 주기에서 발생하는 탄소 배출량을 측정된 문헌, 2) 측정된 탄소 배출량을 시각화하는 도구를 개발한 문헌이다. 포함 기준 1) 과 2) 를 만족시키지 않는 문헌, 학술지나 학회지 논문이 아닌 문헌은 분석에서 배제되었다.

2.3 문헌 선정

수집된 문헌에서 중복 문헌 (n=46) 을 제외한 456 개의 문헌 중 5 개만이 선택 및 포함 기준에 따라 체계적 문헌고찰에 포함되었다. 1 차 배제 문헌 선별에서는 학술지나 학회지 논문이 아닌 Review paper (n=27), Conference review (n=18), Book (n=13), Survey (n=1), Editorial (n=1), Magazine (n=1), Perspective and Opinion (n=2) 을 배제했다. 이어, 2 차 배제 문헌 선별에서는 인공지능 모델 개발 주기에서 발생하는 탄소 배출량을 측정하지 않은 문헌 (n=379), 측정한 탄소 배출량을 시각화하는 도구를 개발하지 않은 문헌 (n=9) 을 배제했다. 이러한 과정을 통해 5 개의 문헌을 최종 선정했다. 그림 1 은 PRISMA 가이드라인에 따른 문헌 선별 과정을 보여준다.

표 1. 최종 분석 대상 논문들에 대한 분석 결과 요약

저자, 연도	1. 개발한 도구를 어떤 인공지능 모델 대상으로 평가했는가?	2. 인공지능 모델 개발 주기의 어떤 단계에서 발생한 탄소 배출량을 측정했는가?	3. 측정한 탄소 배출량 시각화에 사용한 지표는 무엇인가?	4. 개발한 시각화 도구가 정보 시각화 레퍼런스 모델의 어떤 단계까지 지원하는가?	5. 개발한 시각화 도구의 타깃 사용자는 누구인가?
Henderson et al., 2020	사전 학습된 이미지 분류 모델, 강화 학습	데이터 전처리, 실험, 훈련, 추론	탄소 배출량	시각적 구조	머신러닝 연구자
Shaikh et al., 2021	평가하지 않았고, 사용자 시나리오만 제시함	훈련	에너지 소비량, 탄소 발자국	Views	머신러닝 활용하는 연구자와 실무자
Budennyy et al., 2022	텍스트 기반 이미지 생성 모델	훈련, 추론	에너지 소비량, 지역별 탄소 배출량	데이터 표	데이터 과학자와 연구자
Yoo et al., 2023	텐서플로 허브의 이미지 영역에서 이미지 분류 모델	추론	탄소 집약도	Views	온라인 커뮤니티의 머신러닝 개발자
Zhang et al., 2024	대규모 생성형 인공지능 모델	훈련, 추론	탄소 집약도	데이터 표	생성형 인공지능 모델 사용자

2.4 문헌 분석

문헌 선정 과정에 참여한 5 명의 검토자가 구글 스프레드시트를 활용해 선정된 문헌의 정보를 체계적으로 수집하고 분석했다. 분석 항목으로는 저자, 출판 연도, 개발한 도구의 특성, 탄소 배출량 측정 대상 인공지능 모델의 특성, 시각화 지표, 타깃 사용자가 포함되었다. 이어 4 명의 연구자가 분석 결과를 교차 확인 (cross-check) 하여 타당성을 검토한 뒤 결과를 표로 제시했다.

3 결과

서론에서 제시한 5 개의 연구 질문에 대한 답을 찾기 위해 데이터베이스에서 5 개의 문헌을 분석 대상으로 선정했으며, 문헌에 대한 분석 결과를 표 1에 제시했다.

3.1 개발한 도구로 어떤 인공지능 모델을 평가했는가?

최종 분석 대상에 포함된 5 개 논문 중, 총 4 개 논문은 개발한 도구로 인공지능 모델을 평가했다. 그중 2 편은 이미지 분류 모델을 대상으로 했고, 나머지 2 편은 생성형 모델을 대상으로 평가했다. Yoo et al.[12]은 텐서플로 허브의 ImageNet-21k 데이터셋을 사용하여 학습된 이미지 분류 모델을 평가 대상으로 삼았다. 유사하게, Henderson et al.[13]도 사전 학습된 이미지 분류 모델에 더해, 강화 학습 모델의 탄소 배출량도 측정했다.

생성형 모델을 대상으로 한 평가는 Budennyy et al.[14]과 Zhang et al.[15]의 연구에서 이뤄졌다. Budennyy et al.[14]은 텍스트 기반 이미지 생성 모델인 Malevich와 Kandinsky를 대상으로 하여, 환경적 영향을 분석했다. Zhang et al.[15]는 Mistral, Vicuna, 그리고 Stable Diffusion과 같은 대규모 생성형 인공지능 모델을 대상으로 개발된 도구가 상당한 탄소 절감 효과를 달성할 수 있음을 보였다.

3.2 인공지능 모델 개발 주기의 어떤 단계에서 발생한 탄소 배출량을 측정했는가?

인공지능 모델 개발 주기는 데이터 전처리, 실험, 훈련, 추론의 4 단계로 나눌 수 있다[16]. 데이터 전처리 단계에서는 데이터를 수집하고, 특징을 추출한다. 실험 단계에서는 알고리즘, 아키텍처, 훈련 방법의 품질을 설계, 구현, 평가한다. 훈련 단계에서는 인공지능 솔루션을 평가하고, 추론 단계에서는 가장 적합한 모델을 배포한다.

5 개 논문 중 훈련 단계와 추론 단계에서 발생한 탄소 배출량을 측정한 논문은 각각 4 개였다. Shaikh et al.[17]은 훈련 단계만, Yoo et al.[12]은 추론 단계에서만 측정했다. Budennyy et al.[14], Zhang et al.[15]은 두 단계 모두에서 탄소 배출량을 측정했다.

3.3 측정한 탄소 배출량 시각화에 사용한 지표는 무엇인가?

탄소 배출량 (Carbon Emission), 탄소 집약도 (Carbon Intensity), 탄소 발자국 (Carbon Footprint), 에너지 소비량 (Energy Consumption) 등을 탄소 배출량 측정 및 시각화 지표로 사용했다. 탄소 배출량은 말 그대로 배출되는 CO₂의 양을, 탄소 집약도란 특정 단위 생산량 (예: kWh, GDP) 당 배출되는 CO₂의 양을 의미한다. 탄소 발자국은 제품이나 서비스 생산 전 과정에서 발생하는 온실가스 배출량을, 에너지 소비량은 활동을 위해 쓰이는 에너지의 총량을 뜻한다.

최종 분석 대상 논문 5 개에서 사용한 지표의 빈도는 탄소 집약도 2 회, 탄소 배출량 2 회, 탄소 발자국 1 회, 에너지 소비량 2 회였다. Yoo et al.[12]와 Zhang et al.[15]은 탄소 집약도를, Henderson et al.[13]은 탄소 배출량을 지표로 삼았다. Budennyy et al.[14]과 Shaikh et al.[17]은 공통으로 에너지 소비량을 사용했고, 각각 탄소 배출량과 탄소 발자국을 추가적인 지표로 삼았다.

3.4 개발한 시각화 도구가 정보 시각화 레퍼런스 모델의 어떤 단계까지 지원하는가?

정보 시각화 레퍼런스 모델에서 시각화 단계는 다음과 같이 총 4 단계로 나뉜다: 원시 데이터, 데이터 표, 시각적 구조, Views[18]. 가공되지 않은 원시 데이터는 변환 과정을 거쳐 데이터 표 형태로 바뀌고, 이후 시각적 매핑 또는 인코딩을 통해 시각적 구조, 즉 차트나 그래프로 전환된다. 여러 개의 차트를 만들고 이들 사이의 상호작용을 정리한 Views가 생성된다. Views는 사용자가 제시된 그림을 보고 해석하는 시각화 매핑의 최종 결과물을 의미한다. 따라서 본 연구에서는 해당 모델에서 2 단계에서 4 단계까지를 차용하여 시각화 단계를 정의했다.

최종 분석 대상 논문 5 개 중 데이터 표 단계 2 개, 시각적 구조 단계 1 개, Views 단계 2 개가 있었다. Budennyy et al.[14]과 Zhang et al.[15]은 CSV 파일을 제공하여 데이터 표 단계에 속한다. 특히, Zhang et al.[15]는 절감된 총 배출량, 리더렉션 요청 수, 지역별 요청 수를 제공한다는 특징이 있다. Henderson et al.[13]은 여러 차트를 제공하나, 차트 간 상호작용이 없어 시각적 구조 단계에 속한다. Yoo et al.[12]는 Views 단계로, 사용자가 탄소 집약도나 선택한 모델의 이름을 기준으로 추론 단계에서 생성된 탄소 집약도 차트를 정렬할 수 있다. 또한, 해당 모델의 추론 단계에서 발생하는 탄소 집약도의 비율과 추론 결과를 내림차순으로 정렬해 보여준다. Shaikh et al.[17] 역시 Views 단계로, 사용자는 소비량 차트를 통해 선택한 모델의 에너지 및

탄소 소비량을 확인할 수 있고, 모델 지역 보기를 사용하여 모델이 학습된 지역을 확인할 수 있다.

그러나 탄소 배출량을 Views 단계까지 시각화한 논문은 전체에서 2 편뿐이며, 각각의 도구도 명확한 한계점이 존재한다. 사용자가 원하는 모델 간 탄소 배출량을 시각적으로 비교하는 기능을 제공하는 Yoo et al.[12]은 텐서플로 허브에서만 사용 가능하다는 제약이 있다. 한편, 지역 간 탄소 배출량을 시각적으로 비교하는 기능을 제공하는 Shaikh et al.[17]은 미국 내 비교만 가능하다는 데에 한계가 있다.

3.5 개발한 시각화 도구의 타깃 사용자는 누구인가?

인공지능 모델을 대상으로 사용하는 시각화 도구를 제시한 만큼, 도구의 타깃 사용자는 개발자와 연구자로 나타났다. Yoo et al.[12]은 텐서플로 허브 온라인 커뮤니티의 머신러닝 개발자를 주 사용자로 설정했다. Henderson et al.[13], Budennyy et al.[14], Shaikh et al.[17]의 세 논문에서는 모두 연구자를 대상으로 시각화 도구를 개발했다. 특히 Budennyy et al.[14]은 데이터 과학자 및 연구자를, 나머지 두 논문의 경우에는 머신러닝 연구자를 대상으로 삼았다. Shaikh et al.[17]은 머신러닝을 활용하는 실무자를 추가적인 타깃 사용자로 명시했다. Zhang et al. [15]는 분석에 포함된 논문 중 유일하게 타깃 사용자로 생성형 인공지능 모델 사용자를 명시한 논문이었다. 이렇듯 현재까지의 시각화 도구 디자인 연구들은 타깃 사용자를 구체적으로 명시하지 않는 경향이 있을 뿐 아니라, 개발한 도구에 대해 사용자 평가를 진행하지 않았다는 데에 한계가 있었다.

4 고찰

본 연구에서는 지속 가능한 인공지능 개발을 위해 인공지능 모델에서의 탄소 배출량을 측정하고, 이를 사용자에게 시각화하여 제공하는 도구를 개발한 논문들을 분석했다. 분석에 포함된 5 개 논문 중, 실제로 시각화 도구를 사용할 타깃 사용자의 니즈를 반영하여 도구를 제작한 연구가 없다는 것을 발견했다. 이전 문헌고찰 연구 [19]에서는 특정 플랫폼에 최적화된 인공지능 탄소 발자국 계산 도구 사례들을 분석했다. 그중 하나인 Microsoft Azure Sustainable AI Calculator는 Microsoft Azure 플랫폼 환경에서만 사용할 수 있는 맞춤형 탄소 배출량 측정 도구를 도입하여, 사용자가 다양한 배포 시나리오를 모델링하고 탄소 영향을 비교하도록 지원했다. 이를 통해 해당 플랫폼의 인공지능 개발자들이 모델 훈련 시간을 30%까지 단축하여 탄소 발자국을 줄이는 성과를 거두었다[20]. 또한, MLCO₂ Impact 라이브러리는 맞춤형 탄소 배출 추정을 통해 머신러닝 개발자들이 더욱 정교한 환경 영향을 분석하도록 도왔다. 자연어 처리 연

구 그룹은 이 라이브러리를 활용하여 탄소 영향을 줄이기 위해 언어 모델을 최적화된 실제 사례를 보여주었다[21]. 이 외에도 Carbon Tracker, HPC 등 특정 플랫폼에 최적화된 다양한 지속 가능한 인공지능 도구가 인공지능 개발에 이용되고 있다[19]. 특정 플랫폼에서 기능을 제공하는 도구라도 해당 플랫폼의 인공지능 개발자들에게 있어서 충분한 성과를 거둘 수 있었다는 점으로 미루어 보아, 타깃 사용자의 니즈를 반영하여 범용적인 도구를 개발한다면 더 빠른 속도와 적은 비용으로 지속 가능한 인공지능 개발을 도울 수 있을 것이다.

또한, 우리는 인공지능 모델의 개발 주기 중 데이터 전처리와 실험 과정에서 발생하는 탄소 배출량을 측정하는 도구를 개발한 연구가 없다는 것을 발견했다. 이는 데이터 전처리와 실험 과정에서 발생하는 탄소 배출량을 어떻게 측정할 수 있는지, 그리고 이를 측정하기 어려운 이유가 무엇인지에 대한 의문을 품게 했다. 이전 연구에서는 데이터 과학자들이 지속 가능한 데이터 마이닝 과정을 수행하기 위한 디자인 원칙이 제시되었다[22]. 그 중에는 데이터의 항목, 속성의 숫자 및 크기, 모델의 크기를 줄이는 것뿐만 아니라, 시행착오 횟수를 줄이는 것이 중요함을 확인할 수 있었다. 이와 함께, 이미 계산된 값이나 다른 사람이 만든 모델을 재사용하고 공유하는 것이 중요하다는 점도 확인할 수 있었다. 단순히 전력 소모량과 같은 정량적인 지표만으로 계산이 가능한 훈련이나 추론 단계와는 달리[14], 데이터 전처리나 실험 단계의 경우는 취급하는 데이터나 모델의 하이퍼파라미터, 그리고 다양한 시행착오 등 사람이 개입하여 처리해야 하는 부분이 상당수 존재한다. 따라서 정량적인 지표만으로 측정이 어려운 데이터 전처리나 실험 단계에서 지속 가능한 인공지능 개발자들을 돕기 위한 도구가 필요하다.

5 결론

본 연구의 목적은 인공지능 모델 개발 주기에서 발생하는 탄소 배출량 측정 도구에 대한 연구 동향을 파악하여, 인공지능 모델의 탄소 배출량을 확인하고 관리할 수 있는 도구를 개발하는 데에 기여하는 것이다. 본 연구에서는 체계적 문헌고찰을 통해, 2024년 11월까지 출판된 문헌에서 인공지능 모델의 탄소 배출량을 측정하고 시각화한 도구들의 특징을 분석하여 초기에 설정한 연구 질문에 대한 답을 제시했다. 대부분의 도구가 모델 개발 주기에서 전처리와 실험 단계가 아닌, 훈련과 추론 단계에서 발생하는 탄소 배출량만을 측정했다. 게다가, 타깃 사용자의 니즈를 반영하여 도구를 제작한 연구도 없었다. 특히 탄소 배출량을 시각화하는 방식에 있어서 사용자가 확인하고 비교할 수 있도록 Views를 구현한 논문이 한정적이었으며 시각화 도구에 대한 사용자 평가도

진행하지 않았다. 따라서 탄소 배출량 측정 도구 디자인에 있어서 전처리 및 실험 과정에서 발생하는 탄소 배출량 측정뿐만 아니라, 사용자와의 상호작용을 강화한 사용자 중심적인 시각화 도구의 개발 필요성을 강조한다.

본 연구는 다음의 한계점을 가진다. 우선, 탄소 배출량을 시각화하는 도구를 개발한 논문을 대상으로 분석했지만, 실제로 개발된 도구들이 얼마나 사용되는지는 분석하지 않았다. 또한, 본 연구는 총 3개의 온라인 데이터베이스 Scopus, IEEE Xplore, ACM Digital Library에 게재된 논문만을 대상으로 했기 때문에 해당 데이터베이스에 포함되지 않은 연구는 체계적 문헌고찰에서 제외되었다. 후속 연구에서는 탄소 배출량 시각화 도구에 대한 사용자 평가 및 디자인 원칙을 제시하는 것이 필요하며, arXiv나 Google Scholar 등을 포함해 더 넓은 범위를 대상으로 문헌고찰이 필요하다. 이러한 한계점에도 불구하고, 체계적 문헌고찰을 통해 인공지능 모델 탄소 배출량 시각화 연구를 분석하고, 추가 연구가 필요한 방향을 제시했다는 점에서 관련 연구 활성화에 기여할 수 있을 것으로 기대한다.

사사의 글

이 연구는 서울대학교 신입교수 연구정착금으로 지원되는 연구비에 의하여 수행되었음. 이 성과는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (No. RS-2024-00407105). 본 연구에 조언과 도움을 주신 HCAIL 구성원들에게 감사의 말씀을 전합니다.

참고 문헌

1. Patterson, D., Gonzalez, J., Le, Q., Liang, C., Munguia, L. M., Rothchild, D., So, D., Texier, M. and Dean, J. Carbon emissions and large neural network training. arXiv Preprint. arXiv:2104.10350. 2021.
2. Hope, C. W. Optimal Carbon Emissions and the Social Cost of Carbon Over Time Under Uncertainty. Integrated Assessment Journal. 8(1). pp. 107-122. 2008..
3. Bender, E. M., Gebru, T., McMillan-Major, A., and Shmitchell, S. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?. In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT '21). Association for Computing Machinery. pp. 610-623. 2021.
4. 유태원, 정형구. 지속가능 인공지능 모델 개발자 커뮤니티 탐구: 허깅페이스 온라인 커뮤니티

- 를 중심으로. 한국 HCI 학회 학술대회. pp. 765–769. 2024.
5. Song, A., Chen, D., and Zong, Z. Unveiling the Truth: An Analysis of the Energy and Carbon Footprint of Training an OPT Model using DeepSpeed on the H100 GPU. In Proceedings of the 14th International Green and Sustainable Computing Conference (IGSC '23). Association for Computing Machinery, NY. pp. 36–38. 2024.
6. Andrew A. Chien, Liuzixuan Lin, Hai Nguyen, Varsha Rao, Tristan Sharma, and Rajini Wijayawardana. Reducing the Carbon Impact of Generative AI Inference (Today and in 2035). SIGENERGY Energy Informatics Review. 4(3). pp. 65–72. 2024.
7. Rajkumar P.V. Gauging Carbon Footprint of AI/ML Implementations in Smart Cities: Methods and Challenges. In Proceedings of the 2022 Seventh International Conference on Fog and Mobile Edge Computing (FMEC). Paris. pp. 1–5. 2022.
8. Bloomfield, P. S., Clutton-Brock, P., Pencheon, E., Magnusson, J., and Karpathakis, K. Artificial intelligence in the NHS: climate and emissions. The Journal of Climate Change and Health. 4, Article 100056. 2021.
9. Bouza, L., Bugeau, A., and Lannelongue, L. How to estimate carbon footprint when training deep learning models? A guide and review. Environmental Research Communications. 5(11), Article 115014. 2023.
10. 김수영, 박지은, 서현주, 이윤재, 손희정, 장보형, 서혜선, 신채민. NECA 체계적 문헌고찰 매뉴얼. 한국보건 의료연구원. 2011.
11. Page, M. J., McKenzie, J. E., Bossuyt, P. M. et al. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. Systematic Reviews. 89. pp. 1–11. 2021.
12. Taewon Yoo, Hyunmin Lee, SeungYoung Oh, Hyosun Kwon, and Hyunggu Jung. Visualizing the Carbon Intensity of Machine Learning Inference for Image Analysis on TensorFlow Hub. In Companion Publication of the 2023 Conference on Computer Supported Cooperative Work and Social Computing (CSCW '23 Companion). Association for Computing Machinery, New York. pp. 206–211. 2023.
13. Henderson, P., Hu, J., Romoff, J., Brunskill, E., Jurafsky, D., and Pineau, J. Towards the systematic reporting of the energy and carbon footprints of machine learning. Journal of Machine Learning Research. 21(248), pp. 1–43. 2020.
14. Budennyy, S.A., Lazarev, V.D., Zakharenko, N.N. et al. eco2AI: Carbon Emissions Tracking of Machine Learning Models as the First Step Towards Sustainable AI. Doklady Mathematics. 106(Suppl 1), S118–S128. 2022.
15. Zhang, E., Wu, D., and Boman, J. Carbon-Aware Workload Shifting for Mitigating Environmental Impact of Generative AI Models. In Proceedings of the 2024 IEEE International Conferences on Internet of Things (iThings), IEEE Green Computing & Communications (GreenCom), IEEE Cyber, Physical & Social Computing (CPSCom), IEEE Smart Data (SmartData), and IEEE Congress on Cybermatics. pp. 446–453. 2024.
16. Wu, C. J., Raghavendra, R., Gupta, U. et al. Sustainable AI: Environmental implications, challenges and opportunities. In Proceedings of Machine Learning and Systems 4. pp. 795–813. 2022.
17. Shaikh, O., Saad-Falcon, J., Wright, A. P., Das, N., Freitas, S., Asensio, O., and Chau, D. H. EnergyVis: Interactively Tracking and Exploring Energy Consumption for ML Models. In Extended Abstracts of the 2021 CHI Conference on Human Factors in Computing Systems (CHI EA '21). Association for Computing Machinery, New York. Article 458, pp. 1–7. 2021.
18. Card, S., Mackinlay, J., Shneiderman, B. Readings in Information Visualization: Using Vision To Think. Information Visualization – IVS. 1999.
19. Alzoubi, Y. I., and Mishra, A. Green artificial intelligence initiatives: Potentials and challenges. Journal of Cleaner Production. Article 143090. 2024.

20. Azure, Emissions impact dashboard.
<https://www.microsoft.com/en-au/sustainability/emissions-impact-dashboard>. (Accessed 1 December 2024). 2021.
21. MLCO2, Machine learning has a carbon footprint. <https://mlco2.github.io/impact/>. (Accessed 1 December 2024). 2023.
22. Schneider, J., Seidel, S., Basalla, M., Brocke, J. Reuse, Reduce, Support: Design Principles for Green Data Mining. Business & Information Systems Engineering. 65, pp. 65–83. 2023.